공공입찰 RAG 답변 생성 LLM 비교 평가

공공입찰 RAG 파이프라인 모델 선정 보고서

2026 년 9 월

1. 결론

Qwen3-8B 를 권고한다.

같은 문항·같은 근거·같은 설정으로 10 개 모델을 비교했다. 도입 대상 PC 에서 실행 가능한 9 종 가운데 Qwen3-8B 가 품질 지표 전부에서 1 위였다.

항목	Qwen3-8B	Gemma-3-4B	Llama-3.1-8B
맞는 답을 주는 비율	**84.0%**	**66.8%**	**72.0%**
틀린 답을 주는 비율	14.3%	24.1%	24.2%
근거 번호 정확도	86.5%	85.5%	77.7%
정답 안정도 (지시문을 바꿔도 보장되는 수준)	80.9	53.9	69.1
답변 소요 시간(중앙값)	26.4 초	12.3 초	21.8 초
메모리 사용량	8.28GB	4.06GB	8.19GB

Qwen3-8B 는 관문을 통과한 9 종 가운데 정답 안정도·환각률·인용 정확도 세 지표에서 모두 1 위다. 응답 시간만 9 종 중 8 위로, 대가는 속도와 메모리다.

Gemma-3-4B 는 환각률·인용 정확도에서 2 위이고 응답이 12.3 초로 8B 의 절반 이하라 실질적인 대안이다. 다만 정답 안정도가 53.9 로 낮아 지시문을 바꾸면 성능이 크게 흔들린다(지시문 5 종 표준편차 ±12.9). 자세한 내용은 5 장에 있다.

2. 어떻게 비교했나

비교의 공정성을 위해 모델 이외의 모든 조건을 동일하게 고정했다.

2.0 평가 대상 시스템

평가 대상은 나라장터 공공입찰 공고를 다루는 RAG 질의응답 시스템이다. 입찰 참여 기업의 직원이 회사·역할로 로그인해 공고 요건을 묻고, 시스템은 검색한 근거를 바탕으로 답변을 생성한다. 여러 기업이 한 시스템을 함께 쓰므로 타사 자료가 노출되어서는 안 되고, 같은 회사 안에서도 원가·투찰가는 일부 역할만 볼 수 있어야 한다.

문서는 이 요구에 맞춰 세 등급으로 나뉜다.

등급	내용	색인 범위
L1 공개	공고문·제안요청서	전체 기업 공통
L2 기업 내부	실적·인력·인증	자기 회사만
L3 기업 민감	단가·협력사 견적·투찰 전략	자기 회사 중 허용 역할만

접근통제는 검색 단계에서 처리한다. 질문을 낸 계정의 회사·인증 상태·역할·허용 등급을 문서의 등급·허용 역할과 대조해, 통과하지 못한 문서는 답변 생성 모델의 입력에 넣지 않는다.

평가 문항 300 개 중 사업별 S04 5 문항(access_control)은 권한 없는 역할이 L3 원가 자료를 요청하는 경우다. 5 문항 모두 검색 단계에서 차단되어 근거 0 건으로 기록되었고, 근거가 없으면 모델이 개입할 여지가 없으므로 이 5 문항은 검색 단계의 시험이지 모델의 시험이 아니다. 따라서 모델 비교는 나머지 295 문항으로 한다. 권한 밖 자료가 검색을 통과해 모델까지 도달했을 때의 결과는 부록 B 에 있다.

2.1 후보 10 종

두 축으로 배치했다. 세로축은 Qwen3 한 계열로 크기만 바꿔(1.7B·4B·8B·14B) 성능 차이가 크기에서 오는지 가려낸다. 가로축은 같은 크기대에서 국산(Kanana·Mi:dm)과 글로벌(Gemma·Llama) 모델을 대조한다. 선정 기준은 상업적 이용 가능한 라이선스, 로컬 CPU 구동, 공통 문맥 길이 충족이다.

Gemma 는 계획 단계에서 Gemma-4 E2B·E4B 였으나, 공식 GGUF 의 특수 토큰이 제대로 등록되지 않아 llama.cpp 에서 대화 경계를 인식하지 못했다. 일괄 실행 전에 llama.cpp 에서 검증된 Gemma-3 1B·4B 로 교체했다.

모델	크기	라이선스	선정 이유
Qwen3-1.7B	1.7B	Apache-2.0	크기 사다리 최하단
Gemma-3-1B	1B	Gemma Terms	1B 급 글로벌 대조
Kanana-1.5-2.1B	2.1B	Apache-2.0	2B 급 국산 대조(카카오)
Mi:dm-2.0-Mini	2.3B	MIT	2B 급 국산 대조(KT, 한국어 특화)
Qwen3-4B	4B	Apache-2.0	4B 급 · 크기 사다리
Gemma-3-4B	4.3B	Gemma Terms	4B 급 글로벌 대조
Qwen3-8B	8.2B	Apache-2.0	8B 급 · 크기 사다리
Kanana-1.5-8B	8B	Apache-2.0	8B 급 국산 대조
Llama-3.1-8B	8B	Llama 3.1	8B 급 국제 기준선
Qwen3-14B	14.8B	Apache-2.0	품질 상한 확인

2.2 공통 조건

조건	값	왜 고정했나
양자화	Q4_K_M	모델 파일 압축 방식. 다르면 용량과 품질이 달라짐
문맥 길이	24,576 토큰	근거가 잘리지 않는 길이로 통일
온도(temperature)	0	같은 입력에 항상 같은 답이 나오게 고정
난수 시드	고정	재실행해도 동일 결과
추론 모드	끔	모델별 기본값 차이 제거

도입 환경의 운영 설정은 문맥 4,096 토큰이다. 품질 평가에서 24,576 을 쓴 이유는 문항에 딸린 근거가 길어, 문맥을 줄이면 일부 문항에서 근거가 잘려 모델마다 다른 입력을 받게 되기 때문이다. 메모리는 운영 설정 그대로 측정했다.

2.3 근거를 고정했다

RAG 시스템은 질문을 받으면 먼저 문서를 검색하고, 찾아온 근거를 읽어 답변을 만든다. 이번 평가는 뒤쪽, 즉 답변을 만드는 단계만 비교한다.

근거는 검색으로 찾지 않고, 문항마다 작성자가 원문에서 골라 붙여 둔 인용문을 그대로 사용했다. 10 개 모델이 글자 하나까지 같은 근거를 받았으며, 이 입력 파일은 해시로 기록해 동일성을 검증할 수 있다.

따라서 이 결과는 "근거가 제대로 주어졌을 때의 답변 능력"이다. 운영에서는 검색이 정답 근거를 가져오지 못하는 경우가 있으므로 실제 정답률은 이보다 낮을 수 있다. 검색 품질은 이 평가의 범위 밖이다.

2.4 평가 문항

실제 공공입찰 사업 5 곳의 공고 51 건에서 추출한 300 문항을 사용했다. 문항은 세 종류의 응답을 요구한다.

유형	요구하는 응답	예
답변	근거로 확정해 답한다	제안서 최대 분량은 몇 쪽인가
조건부 답변	조건을 달아 답한다	A 인 경우에만 가능하다
자료부족 안내	근거가 없음을 알린다	제공된 문서로는 확인되지 않는다

300 문항 중 295 문항을 사용했다. 판정자가 답변 전문을 읽는 판정과 규칙 기반 자동 측정을 모두 295 문항 전체에 적용했다. 제외한 5 문항(S04)은 2.0 절에서 설명한 접근통제 문항이다.

2.5 지시문 5 종 — 운을 배제하는 장치

같은 모델이라도 지시문을 어떻게 쓰느냐에 따라 성능이 크게 달라진다. 지시문 하나로만 평가하면 그 지시문이 우연히 잘 맞은 모델이 유리해진다.

이를 막기 위해 지시문을 5 종 준비하고 모든 모델을 5 번씩 평가했다. 지시문은 결과를 보기 전에 분량·배치·제시 방식 세 축을 정해 기계적으로 작성했으며, 특정 모델의 약점을 겨냥한 문구는 넣지 않았다.

지시문	분량	규칙 배치	제시 방식
P1	294 자	형식 먼저	산문
P2	382 자	규칙 먼저	번호 목록
P3	401 자	형식 먼저	산문
P4	490 자	규칙 먼저	번호 + 예시
P5	565 자	형식 먼저	번호 + 역할 부여

보고서의 모든 수치는 5 종 평균이며, ± 뒤의 숫자는 5 종 사이의 표준편차다. 이 값이 클수록 지시문에 민감하다.

총 실험 규모: 10 개 모델 × 295 문항 × 5 종 지시문 = 14,750 건의 답변을 생성하고 전부 판정했다.

3. 무엇을 쟀나

답변 하나하나를 세 갈래로 나누었다. 한 답변은 반드시 셋 중 하나에 속하며, 세 비율의 합은 100%다.

분류	뜻	사용자가 받는 것
정답	**결론이 맞고, 쓴 내용이 전부 근거 안에 있다**	**바로 쓸 수 있는 답**
환각	**근거에 없거나 근거와 어긋나는 내용이 있다**	**틀린 답 — 믿으면 손해**
무응답	질문에 대한 판단이 담기지 않았다	아무것도 없음

"환각"은 결론이 틀린 경우를 포함한다. 근거가 불가라고 하는데 가능하다고 답했다면 그것이 곧 근거와 어긋나는 진술이기 때문이다.

3.1 판정 방법

답변을 읽고 두 가지를 순서대로 확인했다.

① 질문에 대한 판단이 있는가 — "할 수 없다", "가능하다" 같은 가부·방향 표현이 없으면 무응답으로 분류한다.

② 근거를 벗어난 문장이 있는가 — 하나라도 있으면 환각, 없고 결론이 맞으면 정답이다.

판정 기준은 답변을 보기 전에 문서로 확정했고, 판정 중에 바꾸지 않았다. 모델 이름과 지시문 종류는 가린 상태에서 판정했으며, 답변은 전문을 읽고 판정했다. 판정자는 Claude Fable 5.1(Anthropic)이다.

Fable 5.1 은 안전 라우팅에 따라 일부 응답이 다른 모델에서 생성될 수 있으며, 판정자는 이를 구분할 수 없다. 14,750 건 전부에 같은 기준서와 같은 절차를 적용했다.

판정은 세 차례로 나누어 진행했다. 처음 58 문항은 화면에 답변 앞부분만 표시해 판정한 뒤, 답변 끝에 덧붙는 근거 밖 조언이나 없는 조항 번호를 놓칠 수 있어 잘렸던 2,210 건을 전문으로 다시 판정했다(300 건, 13.6% 분류 변경). 이후 42 문항과 195 문항은 처음부터 전문을 보고 판정했다. 세 차례의 정답·환각·무응답 분포는 각각 62.6/27.6/9.8%, 61.9/28.3/9.8%, 61.4/28.5/10.1%로 거의 같아 판정 기준이 일정하게 유지되었음을 보여준다.

3.2 환각의 네 가지 유형

환각은 국제 표준 분류(RAGTruth)에 따라 네 유형으로 나누어 기록했다.

유형	뜻	예
Evident Conflict	근거와 정면으로 어긋남	근거 "4 개사 이하" → 답변 "5 개사 가능"
Subtle Conflict	조건·범위가 미묘하게 어긋남	근거 "10 년 이상" → 답변 "정확히 10 년은 제외"
Evident Baseless	근거에 없는 내용을 지어냄	존재하지 않는 조항 번호·금액
Subtle Baseless	근거를 넘어선 조언을 덧붙임	"사전에 협의하시기 바랍니다"

Evident 는 근거와 나란히 놓으면 바로 보이고, Subtle 은 꼼꼼히 읽어야 보인다.

3.3 무응답의 네 가지 유형

유형	뜻
근거 반복	근거 문장을 옮기기만 하고 판단이 없음
절차 서술	계산 방법만 쓰고 결과값이 없음
파편	문장이 성립하지 않거나 조각만 출력
질문 반복	질문을 되풀이하고 끝남

3.4 규칙 기반 지표

판정과 별개로, 같은 295 문항을 프로그램이 규칙으로 측정했다.

지표	무엇을 재나	점수 반영
형식 준수	지시한 출력 형식(답변:/근거: 두 줄)을 지킨 비율	제외 — 운영 프롬프트 형식과 달라 운영 요구를 반영하지 못함

지표	무엇을 재나	점수 반영
인용 정확도	답변에 적은 근거 번호가 실제 제공 범위 안인 비율	사용 — 운영 프롬프트가 요구하며, 사용자가 원문을 확인하는 경로
수치 재현	기대답의 숫자가 답변에 나온 비율	제외 — 숫자의 쓰임까지 보지 않는 문자열 대조
원문 복사	답변에 근거 문장이 60 자 이상 그대로 들어간 비율	제외 — 운영 프롬프트는 짧은 원문 인용을 오히려 요구

인용 정확도는 근거 번호를 하나도 달지 않은 답변을 0 으로 계산한다. 수치 재현은 기대답에 숫자가 있는 58 문항 기준이다.

이 밖에 응답 시간(중앙값 p50, 상위 5% 경계 p95)과 메모리 사용량을 도입 대상 노트북에서 측정했다.

4. 결과

4.1 답변 품질과 운영

모델	정답	환각	무응답	응답 p50	응답 p95	메모리
Qwen3-14B	87.7 ± 2.8	11.3 ± 1.4	1.0	47.8s	84.8s	14.81GB
Qwen3-8B	**84.0 ± 3.1**	**14.3 ± 1.6**	**1.7**	**26.4s**	**46.1s**	**8.28GB**
Qwen3-4B	72.1 ± 4.0	26.6 ± 5.0	1.2	15.2s	33.8s	4.46GB
Llama-3.1-8B	72.0 ± 2.9	24.2 ± 5.0	3.8	21.8s	34.5s	8.19GB
Kanana-1.5-8B	64.7 ± 5.0	28.4 ± 3.9	6.9	29.2s	54.6s	8.16GB
Gemma-3-4B	66.8 ± 12.9	24.1 ± 2.2	9.1	12.3s	26.0s	4.06GB
Kanana-1.5-2.1B	56.5 ± 9.1	34.0 ± 5.0	9.5	12.3s	26.7s	2.60GB
Mi:dm-2.0-Mini	54.8 ± 17.9	40.2 ± 11.1	4.9	6.1s	13.2s	2.88GB
Qwen3-1.7B	48.9 ± 8.6	46.4 ± 8.5	4.6	8.1s	15.2s	2.25GB
Gemma-3-1B	9.7 ± 5.0	33.2 ± 16.4	57.2	7.5s	18.0s	1.04GB

정답 + 환각 + 무응답 = 100%. ± 뒤는 지시문 5 종 표준편차. 응답 시간은 워크스테이션 CPU 실측(문맥 24,576·스레드 12)이며 모델 간 비교용이다. 도입 대상 노트북에서는 약 0.7 배로 더 빠르다. 메모리는 도입 환경의 운영 설정(문맥 4,096·KV 압축·CPU 전용)에서 직접 측정한 최대 점유량이다.

상위 두 모델과 나머지의 격차가 크다. Qwen3-14B 와 8B 는 맞는 답이 84~88%인 반면 나머지는 72% 이하다.

4.2 환각 유형별

모델	환각	Evident Conflict	Subtle Conflict	Evident Baseless	Subtle Baseless
Qwen3-14B	11.3	5.2	4.9	0.1	1.2
Qwen3-8B	**14.3**	**5.2**	**6.8**	**0.3**	**2.0**
Qwen3-4B	26.6	15.1	7.1	0.3	4.1
Llama-3.1-8B	24.2	8.4	12.5	0.4	2.9
Kanana-1.5-8B	28.4	14.6	9.6	0.1	4.1
Gemma-3-4B	24.1	9.8	10.6	0.5	3.1
Kanana-1.5-2.1B	34.0	13.8	9.3	1.1	9.8
Mi:dm-2.0-Mini	40.2	29.6	7.9	0.3	2.4
Qwen3-1.7B	46.4	23.8	14.5	1.3	6.8
Gemma-3-1B	33.2	19.7	5.5	6.4	1.6

Qwen3-8B 와 14B 는 Evident Baseless 가 0.3%·0.1%다. 1,475 건 가운데 존재하지 않는 조항이나 금액을 만들어낸 답변이 각각 4 건·2 건이다. 반면 Qwen3-4B 는 근거와 정면으로 어긋나는 답(Evident Conflict)이 15.1%로 일곱 건에 한 건꼴이고, Mi:dm-2.0-Mini 는 29.6%에 이른다.

4.3 무응답 유형별

모델	무응답	근거 반복	절차 서술	파편	질문 반복
Qwen3-14B	1.0	1.0	0.0	0.0	0.0
Qwen3-8B	**1.7**	**1.6**	**0.1**	**0.1**	**0.0**
Qwen3-4B	1.2	0.7	0.1	0.5	0.0
Llama-3.1-8B	3.8	3.5	0.1	0.2	0.0
Kanana-1.5-8B	6.9	5.9	0.6	0.4	0.0
Gemma-3-4B	9.1	8.8	0.1	0.1	0.0
Kanana-1.5-2.1B	9.5	8.9	0.5	0.0	0.1
Mi:dm-2.0-Mini	4.9	4.1	0.1	0.5	0.1

모델	무응답	근거 반복	절차 서술	파편	질문 반복
Qwen3-1.7B	4.6	3.0	0.6	0.1	0.9
Gemma-3-1B	57.2	45.8	0.0	6.0	5.4

Gemma-3-1B 는 절반 이상이 답변으로 성립하지 않는다. 상위 모델은 2% 이하다.

4.4 규칙 기반 지표

모델	형식 준수	인용 정확도	수치 재현	원문 복사
Qwen3-14B	100.0 ± 0.0	87.9	50.7	0.3
Qwen3-8B	**100.0 ± 0.0**	**86.5**	**49.3**	**2.0**
Qwen3-4B	99.0 ± 1.4	79.0	44.3	5.3
Llama-3.1-8B	98.6 ± 2.0	77.7	51.0	6.6
Kanana-1.5-8B	80.2 ± 43.3	64.3	45.1	2.9
Gemma-3-4B	79.8 ± 42.0	85.5	50.9	3.3
Kanana-1.5-2.1B	82.4 ± 36.4	83.3	54.3	18.4
Mi:dm-2.0-Mini	68.6 ± 38.8	36.1	45.5	6.1
Qwen3-1.7B	99.5 ± 0.3	79.1	43.3	9.6
Gemma-3-1B	16.3 ± 8.8	14.2	30.8	29.9

형식 준수의 표준편차에 주목할 필요가 있다. Qwen3 계열과 Llama 는 ±0~2 로 지시문이 바뀌어도 형식을 지키지만, Kanana 계열·Gemma-3-4B·Mi:dm 은 ±36~43 이다. 네 지시문에서는 98~100%인데 예시를 넣은 지시문(P4) 하나에서 0~17%로 무너진다. 운영 중 지시문을 수정할 때 취약한 모델을 가려낸다.

수치 재현은 모든 모델이 31~54% 수준이다. 어느 모델을 쓰더라도 금액·마감일 같은 숫자는 사람이 원문과 대조해야 한다.

5. 모델 선정

측정값에서 결론으로 가는 과정을 두 단계로 나누었다. 먼저 쓸 수 없는 모델을 걸러내고, 남은 모델만 점수로 순위를 매겼다.

5.1 1 단계 — 관문

메모리가 도입 대상 PC 에 들어가지 않으면 다른 지표가 아무리 좋아도 쓸 수 없다. 이 조건만 통과·탈락으로 판정하고, 나머지는 모두 점수로 다룬다.

조건	기준	근거
메모리	10GB 이하	도입 대상 PC 는 16GB. 브라우저 등 다른 프로그램과 함께 쓰려면 10GB 이하여야 함

모델	메모리(실측)	판정
Qwen3-14B	14.81GB	탈락 — 메모리 초과
Qwen3-8B	**8.28GB**	**통과**
Qwen3-4B	**4.46GB**	**통과**
Llama-3.1-8B	**8.19GB**	**통과**
Kanana-1.5-8B	**8.16GB**	**통과**
Gemma-3-4B	**4.06GB**	**통과**
Kanana-1.5-2.1B	**2.60GB**	**통과**
Mi:dm-2.0-Mini	**2.88GB**	**통과**

모델	메모리(실측)	판정
Qwen3-1.7B	**2.25GB**	**통과**
Gemma-3-1B	**1.04GB**	**통과**

Qwen3-14B 는 14.81GB 로, 도입 PC 에서 다른 프로그램을 거의 띄울 수 없다. 품질은 가장 높지만 실행 조건을 충족하지 못해 제외했다.

기준 10GB 는 도입 PC 16GB 에서 운영체제와 업무 프로그램이 쓰는 5~6GB 를 제외한 값이다. 이 값은 결론을 좌우하는 유일한 기준이므로 주의가 필요하다. 8GB 로 낮추면 Qwen3-8B(8.28GB)가 탈락해 1 위가 Qwen3-4B 로 바뀐다.

응답 시간은 관문에 넣지 않았다. 느려도 답은 나오므로 "못 쓴다"는 선을 그을 근거가 없고, 기준값을 임의로 정하면 그 숫자가 결론을 만들기 때문이다. 응답 시간은 점수에서 다룬다.

상업적 사용이 가능한 라이선스는 후보 10 종을 고를 때 적용한 조건이므로 관문에 넣지 않았다.

5.2 2 단계 — 지표별 비교

평가 지표 관리 규정은 "임의 가중 합산 점수로 순위를 만들지 않는다"고 정한다. 따라서 결론은 지표별 비교로 내리고, 가중 점수는 참고로만 제시한다.

관문을 통과한 9 종을 네 지표로 각각 줄 세운 결과다. 괄호 안이 순위다.

모델	정답 안정도	환각률	인용 정확도	응답 시간	1 위 항목 수
Qwen3-8B	**80.9 (1)**	**14.3 (1)**	**86.5 (1)**	**26.4s (8)**	**3**
Qwen3-4B	68.1 (3)	26.6 (4)	79.0 (5)	15.2s (6)	0
Llama-3.1-8B	69.1 (2)	24.2 (3)	77.7 (6)	21.8s (7)	0
Gemma-3-4B	53.9 (5)	24.1 (2)	85.5 (2)	12.3s (4)	0
Kanana-1.5-8B	59.7 (4)	28.4 (5)	64.3 (7)	29.2s (9)	0
Kanana-1.5-2.1B	47.4 (6)	34.0 (7)	83.3 (3)	12.3s (5)	0
Qwen3-1.7B	40.3 (7)	46.4 (9)	79.1 (4)	8.1s (3)	0
Midm-2.0-Mini	36.9 (8)	40.2 (8)	36.1 (8)	6.1s (1)	1
Gemma-3-1B	4.7 (9)	33.2 (6)	14.2 (9)	7.5s (2)	0

Qwen3-8B 는 품질 세 지표(정답 안정도·환각률·인용 정확도)에서 모두 1 위다. 응답 시간만 9 종 중 8 위로, 이 하나를 제외하면 어느 지표로 줄을 세워도 1 위다.

2 위권은 지표마다 다르다. Llama-3.1-8B 는 정답 안정도 2 위이나 인용 정확도 6 위, Gemma-3-4B 는 환각률·인용 정확도 2 위이나 정답 안정도 5 위, Qwen3-4B 는 정답 안정도 3 위이나 환각률 4 위다. 즉 1 위는 지표 선택과 무관하게 정해지고, 2 위 이하는 무엇을 중시하느냐에 따라 달라진다.

5.3 참고 — 가중 점수

네 지표를 하나의 숫자로 묶으면 비교가 쉬워지므로 참고 산출을 함께 싣는다. 다만 가중치는 담당자 합의를 거친 값이 아니므로 이 점수로 순위를 확정하지 않는다.

관문을 통과한 모델만 네 지표를 가중 합산했다. 네 지표는 단위가 달라(정답 안정도는 0~100, 응답 시간은 초) 그대로 더하면 숫자가 큰 쪽이 결과를 좌우하므로, 먼저 모두 0~1 로 환산한다.

환산 방법 — 통과 모델 중 최고를 1, 최저를 0 으로 놓는다.

지표 성격	환산식
높을수록 좋음 (정답 안정도, 인용 정확도)	(내 값 − 최저) ÷ (최고 − 최저)
낮을수록 좋음 (환각률, 응답 시간)	(최고 − 내 값) ÷ (최고 − 최저)

낮을수록 좋은 두 지표는 뺄셈 방향을 뒤집어 "높을수록 좋은 값"으로 바꾼다. 환각률이 가장 낮은 모델이 1, 가장 높은 모델이 0 이 된다.

점수 = (3×정답 안정도 + 3×환각률 + 1×인용 정확도 + 1×응답 시간) ÷ 8 × 100　(모두 환산값)

가중치 합 8 로 나누므로 모든 지표에서 1 위인 모델이 100 점, 모든 지표에서 꼴찌인 모델이 0 점이 된다.

지표	가중치	방향
정답 안정도	3	높을수록 좋음
환각률	3	낮을수록 좋음
인용 정확도	1	높을수록 좋음
응답 시간	1	낮을수록 좋음

정답률 대신 정답 안정도(정답률 평균 − 표준편차)를 쓴다. 같은 정답률이라도 지시문에 따라 크게 흔들리는 모델은 운영 중 지시문 수정 한 번에 성능이 떨어질 수 있기 때문이다. 정답 안정도에는 정답률이 이미 포함되어 있으므로 정답률을 따로 넣으면 같은 것을 두 번 세게 된다.

계산 예 — Qwen3-8B

지표	통과 9 종 최저	통과 9 종 최고	Qwen3-8B	환산값
정답 안정도	4.7	80.9	80.9	1.000
환각률	14.3	46.4	14.3	1.000
인용 정확도	14.2	86.5	86.5	1.000
응답 시간	6.1 초	29.2 초	26.4 초	0.121

점수 = (3×1.000 + 3×1.000 + 1×1.000 + 1×0.121) ÷ 8 × 100 = 89.0

품질 세 지표에서 모두 1 위라 환산값이 1.000 이고, 응답 시간에서만 0.121 을 받았다. 가장 빠른 모델(6.1 초)과 가장 느린 모델(29.2 초) 사이에서 26.4 초는 느린 쪽에 가깝기 때문이다.

순위	모델	점수	정답 안정도	환각	인용	응답 p50
1	**Qwen3-8B**	**89.0**	**80.9**	**14.3**	**86.5**	**26.4s**
2	Qwen3-4B	73.1	68.1	26.6	79.0	15.2s
3	Llama-3.1-8B	72.6	69.1	24.2	77.7	21.8s
4	Gemma-3-4B	71.7	53.9	24.1	85.5	12.3s
5	Kanana-1.5-8B	56.8	59.7	28.4	64.3	29.2s
6	Kanana-1.5-2.1B	56.6	47.4	34.0	83.3	12.3s
7	Qwen3-1.7B	40.2	40.3	46.4	79.1	8.1s
8	Midm-2.0-Mini	39.4	36.9	40.2	36.1	6.1s
9	Gemma-3-1B	27.2	4.7	33.2	14.2	7.5s

5.4 가중치를 바꿔도 결론이 같은가

가중치 3·3·1·1 은 사람이 정한 값이다. 이 값에 결론이 기대지 않는지 확인하기 위해, 네 가중치를 각각 0.5~3.0 사이에서 무작위로 뽑아 점수를 다시 매기는 일을 3,000 번 반복하고 각 모델이 1 위를 차지한 비율을 셌다.

모델	1 위를 차지한 비율
Qwen3-8B	**56.4%**
Qwen3-4B	2.0%
Gemma-3-4B	41.6%

Qwen3-8B 가 절반 이상(56.4%)에서 1 위다. 다만 속도를 품질만큼 무겁게 보는 가중치에서는 Gemma-3-4B 가 앞선다(41.6%). Gemma-3-4B 는 응답이 12.3 초로 8B 의 절반 이하지만 정답 안정도는 53.9 로 8B(80.9)보다 크게 낮다.

환산 기준이 통과 모델의 최고·최저이므로 후보 구성이 달라지면 환산값도 달라진다. 하위 모델을 제외하며 4 종까지 줄여 계산해도 1 위는 Qwen3-8B 로 같았다. 가중치를 1~5 사이 정수로 바꿔 625 가지를 모두 계산해도 결과가 같다(Qwen3-8B 55.2%, Gemma-3-4B 42.2%, Qwen3-4B 2.6%). 다만 다른 가중치를 3·3·1 로 둔 채 속도 가중치만 4 이상으로, 즉 품질 항목 하나보다 무겁게 잡으면 1 위가 Gemma-3-4B 로 바뀐다. 이 평가는 공공입찰 문서 검토에서 틀린 답의 대가가 대기 시간보다 크다고 보아 속도를 1 로 두었다.

6. 도입 전 확인할 것

이번 평가는 모델만 비교하기 위해 운영과 다른 조건을 일부 사용했다. 도입 전에 운영 조건에서 확인할 항목은 다음과 같다.

항목	이번 평가	운영	확인 방법
프롬프트	평가용 형식	판단/근거/유보사항	운영 프롬프트로 재측정
온도	0	0.7	운영 설정에서 답변 흔들림 확인
근거	문항의 인용문	검색 결과 최대 4 개	실제 검색으로 정답률 확인
문맥 길이(품질)	24,576	4,096	근거가 잘린 상태의 정답률 확인

메모리는 운영 설정에서 직접 측정했으므로 관문 결과는 확정이다. 남은 것은 운영 프롬프트와 실제 검색을 적용했을 때의 품질이다. 운영에서는 문맥 4,096 에 근거를 맞춰 넣으므로 근거 일부가 잘리며, 이 조건에서 정답률은 이번 결과보다 낮을 수 있다.

도입 PC 에서의 실사용 확인

이번 메모리·응답 시간은 모델 서버 하나만 띄운 상태에서 측정한 값이다. 실제 도입 환경에서는 검색·권한 필터·환각 탐지 모델이 함께 돌아가고, 실무자는 브라우저와 문서 프로그램도 같이 쓴다. 도입 전에 전체 시스템을 도입 PC 에 올린 상태에서 다음을 확인해야 한다.

확인 항목	보는 값	판단 기준
전체 메모리 점유	모델 서버 + 검색 + 탐지 모델 + 업무 프로그램 합계	PC 물리 메모리 안에서 스왑이 일어나지 않는가
실사용 응답 시간	질문 입력부터 화면에 답이 나올 때까지	검색·탐지 시간이 더해져 모델 단독 측정값보다 길어짐
동시 사용	여러 명이 같은 PC 를 쓰거나 질문이 몰릴 때	메모리와 응답 시간이 함께 나빠지는 구간 확인

이번 측정에서 Qwen3-8B 는 8.28GB, 검색·탐지 구성 요소는 별도다. 합계가 PC 여유 메모리를 넘으면 디스크 스왑이 일어나 응답 시간이 수 배로 늘어난다. 스왑이 시작되면 모델 성능과 무관하게 시스템을 쓸 수 없으므로, 실사용 확인은 도입 판단의 마지막 조건이다.

부록 A. 추론 모드(thinking)를 켜면 나아지는가

Qwen3 계열은 답변 전에 추론 과정을 생성하는 모드를 제공한다. 지시문 P3, 58 문항에서 켰을 때와 껐을 때를 같은 기준으로 판정했다.

모델	정답 끔 → 켬	환각 끔 → 켬
Qwen3-1.7B	44.8 → 46.6	46.6 → 48.3
Qwen3-4B	70.7 → 77.6	29.3 → 20.7
Qwen3-8B	87.9 → 75.9	10.3 → 24.1
Qwen3-14B	87.9 → 84.5	12.1 → 15.5

Qwen3-4B 만 좋아지고 8B·14B 는 오히려 나빠진다. 추론 과정에서 근거를 넘어선 추론이 답변에 섞이기 때문으로 보인다. 4B 를 켜도 8B 를 끈 상태(87.9%)에 10%p 못 미치면서 생성량은 6 배가 된다. 도입 시 추론 모드는 끄고 운영하는 것이 타당하다.

부록 B. 이 평가에서 다루지 않은 것

· 검색 품질 — 어떤 근거를 가져올지는 검색 단계의 문제이며, 이번 평가는 근거를 고정해 모델만 비교했다.

· 환각을 줄이는 방법 — 어느 모델이 덜 틀리는가까지만 다룬다. 환각 탐지·표시는 별도 시스템이 담당한다.

· 권한 제어 — 2.0 절의 검색 단계 접근통제가 담당한다. 권한 밖 자료가 근거에 섞였을 때를 별도 실험한 결과 10 종 중 7 종이 정보를 그대로 노출했다. 모델을 권한 방어선으로 쓸 수 없으며 검색 단계 권한 필터가 유일한 방어선이다.

부록 C. 한계

· 판정자가 단일 모델(Claude Fable 5.1)이다. 기준을 문서로 고정하고 모델명을 가린 상태에서 판정했으나, 다른 판정자가 판정하면 일부 결과가 달라질 수 있다. 사람 판정과의 일치도는 측정하지 않았다.

· 평가 프롬프트는 지시 내용(근거만 사용, 부족하면 밝힐 것, 근거번호 표기)은 운영과 같으나 출력 형식이 다르다. 운영 프롬프트 형식으로는 시험하지 않았다.

· 인용 정확도는 평가 프롬프트 형식 때문에 두 가지 번호 표기를 모두 인용으로 인정했으며, 번호가 유효 범위 안이어도 엉뚱한 근거를 가리키는 경우는 측정하지 못했다.

· 메모리와 응답 시간은 모델 서버만 단독으로 띄운 값이다. 검색·환각 탐지 등 다른 구성 요소와 업무 프로그램을 함께 올린 실사용 조건은 측정하지 않았다.

· 응답 시간은 워크스테이션 CPU 에서 측정했다. 도입 대상 노트북에서는 약 0.7 배로 더 빠르므로 절대값이 아니라 모델 간 비교로 읽어야 한다. 메모리는 도입 환경의 운영 설정으로 직접 측정했다.

· 문항 일부는 질문 표현이 모호해 모든 모델이 같은 형태로 답했다. 해당 문항은 모델 능력 차이를 반영하지 못한다.