평가 지표 계산식

공공입찰 RAG 답변 생성 LLM 비교 평가

2026년 10월

1 기호

평가 문항 집합을 $\mathcal{Q}$, 후보 모델 집합을 $\mathcal{M}$, 지시문 집합을 $\mathcal{P} = \{P_1, \dots, P_5\}$라 한다. 본 평가에서 $|\mathcal{Q}| = 295$(접근통제 문항 5개 제외), $|\mathcal{M}| = 10$이다. 모델 m이 지시문 p로 문항 q에 생성한 답변을 $a_{m,p,q}$, 문항 q에 고정 제공한 근거 블록을 $e_q^{(1)}, \dots, e_q^{(n_q)}$, 기대 답을 e_q^*로 쓴다.

기호	의미
$\mathcal{Q}$	평가 문항 집합, $\lvert\mathcal{Q}\rvert = 295$
$\mathcal{Q}_{m,p}^{\mathrm{ok}}$	모델 m·지시문 p에서 정상 생성된 답변의 문항 집합
$\mathcal{Q}^{\mathrm{num}}$	기대 답에 수치가 있는 문항 집합, $\lvert\mathcal{Q}^{\mathrm{num}}\rvert = 58$
$\mathcal{M}$, $\mathcal{M}_{\mathrm{pass}}$	후보 모델 집합, 메모리 관문 통과 모델 집합
$\mathcal{P}$	지시문 집합, $\lvert\mathcal{P}\rvert = 5$
$j_{m,p,q}$	답변 $a_{m,p,q}$의 판정 라벨
$\mathcal{H}$	환각 유형 집합 $\{\mathrm{EC}, \mathrm{SC}, \mathrm{EB}, \mathrm{SB}\}$
$\mathcal{F}$	무응답 유형 집합 $\{\mathrm{RE}, \mathrm{PR}, \mathrm{FR}, \mathrm{QR}\}$
$\mathbf{1}[\cdot]$	지시 함수(조건이 참이면 1, 거짓이면 0)

무응답 유형은 근거 반복(RE), 절차 서술(PR), 조각(FR), 질문 반복(QR)이다.

2 판정 기반 지표

2.1 판정 라벨

판정 라벨 집합은 $\mathcal{L} = \{\mathrm{c}\} \cup \mathcal{H} \cup \mathcal{F}$이다. 답변 a가 질문에 대한 판단(가부·방향)을 담고 있는지를 $\delta(a)$, 근거에서 벗어난 내용의 유형 집합을 $T(a) \subseteq \mathcal{H}$라 하면 라벨은 다음 순서로 정해진다.

$$j(a) = \begin{cases} f(a) \in \mathcal{F}, & \delta(a) = 0 \\ \max_{\succ} T(a), & \delta(a) = 1,\ T(a) \neq \varnothing \\ \mathrm{c}, & \delta(a) = 1,\ T(a) = \varnothing \end{cases} \tag{1}$$

여기서 $f(a)$는 무응답의 형태이고, 한 답변에 환각 유형이 여럿이면 심각도 순서 $\mathrm{EC} \succ \mathrm{EB} \succ \mathrm{SC} \succ \mathrm{SB}$에서 가장 심한 하나를 택한다.

2.2 정답률·환각률·무응답률

모델 m, 지시문 p에 대해

$$\mathrm{Acc}_{m,p} = \frac{100}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \mathbf{1}[j_{m,p,q} = \mathrm{c}] \tag{2}$$

$$\mathrm{Hal}_{m,p} = \frac{100}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \mathbf{1}[j_{m,p,q} \in \mathcal{H}] \tag{3}$$

$$\mathrm{Abs}_{m,p} = \frac{100}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \mathbf{1}[j_{m,p,q} \in \mathcal{F}] \tag{4}$$

이며, 세 범주는 서로 배타적이고 전체를 덮으므로 $\mathrm{Acc}_{m,p} + \mathrm{Hal}_{m,p} + \mathrm{Abs}_{m,p} = 100$이다.

유형별 비율은 $t \in \mathcal{H} \cup \mathcal{F}$에 대해

$$R^{(t)}_{m,p} = \frac{100}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \mathbf{1}[j_{m,p,q} = t], \qquad \sum_{t \in \mathcal{H}} R^{(t)}_{m,p} = \mathrm{Hal}_{m,p} \tag{5}$$

이다.

3 지시문 집계와 정답 안정도

지시문별 지표 $X_{m,p}$는 지시문 5종에 대한 평균과 표본표준편차로 보고한다($\bar{X}_m \pm s_X(m)$).

$$\bar{X}_m = \frac{1}{|\mathcal{P}|} \sum_{p \in \mathcal{P}} X_{m,p} \tag{6}$$

$$s_X(m) = \sqrt{\frac{1}{|\mathcal{P}| - 1} \sum_{p \in \mathcal{P}} \left(X_{m,p} - \bar{X}_m \right)^2} \tag{7}$$

정답 안정도는 정답률의 지시문 간 평균에서 표준편차를 뺀 값이다.

$$\mathrm{Stab}_m = \overline{\mathrm{Acc}}_m - s_{\mathrm{Acc}}(m) \tag{8}$$

지시문 표현이 바뀌어도 평균에서 표준편차 하나만큼 낮은 수준은 대체로 유지된다는 의미이며, 정답률이 같아도 지시문에 민감한 모델일수록 낮게 나온다.

4 규칙 기반 자동 지표

자동 지표는 정상 생성된 답변만 대상으로 하며, 추론 블록과 특수 토큰을 제거한 답변 a에 적용한다.

4.1 형식 준수

$$\mathrm{Fmt}_{m,p} = \frac{100}{|\mathcal{Q}^{\mathrm{ok}}_{m,p}|} \sum_{q \in \mathcal{Q}^{\mathrm{ok}}_{m,p}} \mathbf{1}\big[\text{“답변:”} \sqsubseteq a_{m,p,q} \ \wedge\ \text{“근거:”} \sqsubseteq a_{m,p,q}\big] \tag{9}$$

$x \sqsubseteq y$는 문자열 x가 y에 포함됨을 뜻한다.

4.2 인용 정확도

답변이 인용한 근거 번호 집합을

$$C(a) = B(a) \cup G(a) \tag{10}$$

로 정의한다. $B(a)$는 답변 안의 대괄호 번호 $[k]$ 전체이고, $G(a)$는 마지막 "근거:" 줄이 숫자·괄호·구분 기호로만 이루어진 경우 그 줄의 숫자들(아니면 $\varnothing$)이다. 제공된 근거 번호 범위를 $\mathcal{E}_q = \{1, \dots, n_q\}$라 할 때 답변 하나의 인용 정확도와 모델 지표는

$$\pi(a_{m,p,q}) = \begin{cases} \dfrac{|C(a_{m,p,q}) \cap \mathcal{E}_q|}{|C(a_{m,p,q})|}, & C(a_{m,p,q}) \neq \varnothing \\ 0, & C(a_{m,p,q}) = \varnothing \end{cases} \tag{11}$$

$$\mathrm{Cite}_{m,p} = \frac{100}{|\mathcal{Q}^{\mathrm{ok}}_{m,p}|} \sum_{q \in \mathcal{Q}^{\mathrm{ok}}_{m,p}} \pi(a_{m,p,q}) \tag{12}$$

이다. 인용이 없는 답변은 0으로 계산하므로, 이 지표는 "인용을 했는가"와 "인용 번호가 제공 범위 안인가"를 함께 반영한다.

4.3 수치 재현

문자열 x에서 수치 토큰을 추출하는 함수를 $\nu(x)$라 한다. 날짜(YYYY-MM-DD)는 한 토큰으로, 천 단위 쉼표는 제거한 뒤 정수·소수를 토큰으로 본다. 기대 답의 수치 집합을 $N_q = \{u \in \nu(e^*_q) : |u| \geq 2\}$, 수치 문항 집합을 $\mathcal{Q}^{\mathrm{num}} = \{q : N_q \neq \varnothing\}$라 하면

$$\mathrm{Num}_{m,p} = \frac{100}{|\mathcal{Q}^{\mathrm{num}} \cap \mathcal{Q}^{\mathrm{ok}}_{m,p}|} \sum_{q \in \mathcal{Q}^{\mathrm{num}} \cap \mathcal{Q}^{\mathrm{ok}}_{m,p}} \frac{|N_q \cap \nu(a_{m,p,q})|}{|N_q|} \tag{13}$$

이다.

4.4 원문 복사

공백 제거 함수를 $\sigma(\cdot)$, 연결을 $\|$라 하고 $\hat{a} = \sigma(a)$, $\hat{e}_q = \sigma\left(e^{(1)}_q \| \cdots \| e^{(n_q)}_q\right)$, 창 시작 위치 집합을 $I(\hat{a}) = \{0, 20, 40, \dots\} \cap [0, \max(1, |\hat{a}| - 60))$로 두면

$$\mathrm{Copy}(a) = \mathbf{1}[\,|\hat{a}| \geq 60 \ \wedge \ \exists i \in I(\hat{a}) : \hat{a}[i, i+60) \sqsubseteq \hat{e}_q] \tag{14}$$

이고, $\mathrm{Copy}_{m,p}$는 $\mathcal{Q}^{\mathrm{ok}}_{m,p}$에 대한 $\mathrm{Copy}(a)$의 백분율이다. 즉 60자 창을 20자 간격으로 옮기며 근거에 그대로 있는 구간이 하나라도 있는지 본다.

5 운영 지표

문항 하나의 응답 시간 $\tau_{m,q}$는 요청 시작부터 생성 종료까지의 시간이며, 속도 측정 문항 집합 $\mathcal{Q}^{\mathrm{spd}}$($|\mathcal{Q}^{\mathrm{spd}}| = 30$)에서 다음과 같이 요약한다.

$$T^{50}_m = \mathrm{median}_{q \in \mathcal{Q}^{\mathrm{spd}}}\, \tau_{m,q}, \qquad T^{95}_m = \mathrm{Q}_{0.95}\left(\{\tau_{m,q}\}_{q \in \mathcal{Q}^{\mathrm{spd}}}\right) \tag{15}$$

측정 조건은 워크스테이션 CPU, 문맥 24,576, 스레드 12, 최대 생성 512토큰이다.

메모리는 운영 설정(문맥 4,096, KV q8_0, 스레드 8)에서 프로세스 상주 메모리의 최댓값(VmHWM)이다.

$$\mathrm{Mem}_m = \max_t \ \mathrm{RSS}_m(t) \tag{16}$$

6 모델 선정

6.1 관문

$$\mathcal{M}_{\text{pass}} = \{\, m \in \mathcal{M} : \mathrm{Mem}_m \le 10\ \text{GB} \,\} \tag{17}$$

6.2 지표별 순위

선정 지표 $\mathcal{K} = \{k_1, k_2, k_3, k_4\}$와 각 지표의 값 $v_{k,m}$, 방향 d_k는 다음과 같다.

지표 k	값 $v_{k,m}$	방향 d_k	가중치 w_k
k_1 정답 안정도	Stab_m	$+1$	3
k_2 환각률	$\overline{\mathrm{Hal}}_m$	-1	3
k_3 인용 정확도	$\overline{\mathrm{Cite}}_m$	$+1$	1
k_4 응답 시간	T_m^{50}	-1	1

$$\mathrm{rank}_k(m) = 1 + \left|\left\{\, m' \in \mathcal{M}_{\text{pass}} : d_k v_{k,m'} > d_k v_{k,m} \right\}\right| \tag{18}$$

품질 지표 $\mathcal{K}_{\mathrm{Q}} = \{k_1, k_2, k_3\}$에서 1위를 차지한 수를

$$W_m = \sum_{k \in \mathcal{K}_{\mathrm{Q}}} \mathbf{1}[\mathrm{rank}_k(m) = 1] \tag{19}$$

로 두고, 최종 순서는 (W_m, S_m)의 사전식 내림차순으로 정한다. 결론은 지표별 순위에서 내리며, 아래 가중 점수 S_m은 동점 처리와 참고용이다.

6.3 가중 점수(참고)

관문 통과 모델 안에서 지표를 최소–최대 정규화한다. 방향 d_k를 곱해 두 방향을 한 식으로 쓴다.

$$\tilde{v}_{k,m} = \frac{d_k v_{k,m} - \min_{m' \in \mathcal{M}_{\text{pass}}} d_k v_{k,m'}}{\max_{m' \in \mathcal{M}_{\text{pass}}} d_k v_{k,m'} - \min_{m' \in \mathcal{M}_{\text{pass}}} d_k v_{k,m'}} \in [0,1] \tag{20}$$

$$S_m = 100 \cdot \frac{\sum_{k \in \mathcal{K}} w_k\, \tilde{v}_{k,m}}{\sum_{k \in \mathcal{K}} w_k}, \qquad (w_{k_1}, w_{k_2}, w_{k_3}, w_{k_4}) = (3,3,1,1) \tag{21}$$

낮을수록 좋은 지표는 원래 값의 정규화 $M = (v - \min v)/(\max v - \min v)$를 1에서 뺀 것과 같으므로, 식 (21)은 다음의 간단한 꼴로도 쓸 수 있다.

$$S = 100\left[\, w_1 M_{stab} + w_2\big(1 - M_{hallu}\big) + w_3 M_{cite} + w_4\big(1 - M_{latency}\big)\right], \qquad \textstyle\sum_k w_k = 1$$

이때 $(w_1, w_2, w_3, w_4) = \frac{1}{8}(3,3,1,1)$이고, 모델 m에 대해 계산한 S가 식 (21)의 S_m이다.

6.4 가중치 민감도

가중치를 $w_k^{(t)} \overset{\text{iid}}{\sim} \mathcal{U}(0.5,\, 3.0)$로 $T = 3{,}000$회 재추출(난수 시드 3)하여 각 모델이 1위가 되는 비율을 구한다.

$$\text{Win}_m = \frac{100}{T} \sum_{t=1}^{T} \mathbf{1}\left[m = \arg\max_{m' \in \mathcal{M}_{\text{pass}}} \sum_{k \in \mathcal{K}} w_k^{(t)}\, \tilde{v}_{k,m'} \right] \tag{22}$$

격자 검증에서는 무작위 재추출 대신 $\Omega = \{1, 2, 3, 4, 5\}^4$($|\Omega| = 625$)의 모든 가중치 조합에 대해 같은 비율을 계산한다.

$$\text{Win}_m^{\text{grid}} = \frac{100}{|\Omega|} \sum_{\mathbf{w} \in \Omega} \mathbf{1}\left[m = \arg\max_{m' \in \mathcal{M}_{\text{pass}}} \sum_{k \in \mathcal{K}} w_k\, \tilde{v}_{k,m'} \right] \tag{23}$$

7 계산 예시: Qwen3-8B

식 (8)에 따라 $\text{Stab} = 84.0 - 3.1 = 80.9$이다. 관문 통과 9종에서 각 지표의 범위는 정답 안정도 $[4.7,\, 80.9]$, 환각률 $[14.3,\, 46.4]$, 인용 정확도 $[14.2,\, 86.5]$, 응답 시간 $[6.1,\, 29.2]$초이다. Qwen3-8B는 품질 세 지표에서 모두 최선값이므로 $\tilde{v}_{k_1} = \tilde{v}_{k_2} = \tilde{v}_{k_3} = 1$이고, 응답 시간은

$$\tilde{v}_{k_4} = \frac{(-26.4) - (-29.2)}{(-6.1) - (-29.2)} = \frac{2.8}{23.1} = 0.121$$

이다. 따라서 $W = 3$이고, 식 (21)에 의해

$$S = 100 \cdot \frac{3(1) + 3(1) + 1(1) + 1(0.121)}{8} = 89.0$$

이다.

8 구현과의 대응

- 판정 기반 지표(식 2–5)의 분모는 생성 실패를 포함한 $|\mathcal{Q}| = 295$로 고정하고, 자동 지표(식 9–14)의 분모는 정상 생성 답변 수 $|\mathcal{Q}_{m,p}^{\text{ok}}|$(290–295)를 쓴다. 수치 재현의 분모는 57 또는 58이다.
- 식 (8)은 소수 첫째 자리로 반올림한 평균과 표준편차로 계산한다. 식 (18)–(23)도 소수 첫째 자리 값을 입력으로 쓴다.
- 식 (18)에서 동률이 생기면 구현은 모델 입력 순서로 순위를 가른다. 반올림 후 응답 시간이 같은 Gemma-3-4B와 Kanana-1.5-2.1B(12.3초)가 해당하며, 반올림 전 값(12.26, 12.31초)의 순서와 같아 결과는 달라지지 않는다.
- 식 (22)의 구현은 $\sum_k w_k$로 나누지 않은 가중 합을 비교한다. 양의 상수배는 $\arg\max$를 바꾸지 않으므로 식과 같다.
- 대응 코드: 식 (1)–(8)은 `compute_metrics.py`, 식 (9)–(14)는 `score_auto.py`, 식 (17)–(22)는 `select_model.py`.